

Relatório trabalho prático de IBD - Dados públicos

Grupo:

- Henrique Augusto Silva Pedra
- Igor Barroso Almeida
- Leandro Rodrigues Marques
- Maria Clara Pereira de Souza
- Sérgio dos Reis

1. Escolha das fontes de dados

O tema escolhido foi a relação entre condições de saneamento básico e indicadores de saúde da população, considerando que problemas de abastecimento de água, coleta e tratamento de esgoto estão frequentemente associados à ocorrência de doenças e internações hospitalares.

Tendo isso em vista, foram selecionadas duas bases públicas principais:

- No eixo saúde: A base escolhida foi o [DATASUS](#), o departamento responsável pela disponibilização de informações de saúde pública do Sistema Único de Saúde (SUS). A plataforma disponibiliza diversos conjuntos de dados relacionados a internações hospitalares, mortalidade, notificação de doenças, vacinação, atendimentos médicos, entre outros. O órgão que produz os dados disponibilizados pelo DATASUS é o Ministério da Saúde - Governo Federal.
- No eixo saneamento básico: A base escolhida foi o [SNIS](#) (Sistema Nacional de Informações sobre Saneamento), o principal sistema brasileiro de informações sobre saneamento básico, reunindo dados enviados pelos municípios e prestadores de serviços de saneamento. A base contém informações relacionadas a abastecimento de água, coleta de esgoto, tratamento de esgoto, coleta de resíduos sólidos, entre outros.

A ideia principal é fazer relações como: Conectar a incidência de internações por doenças infecciosas com indicadores de saneamento básico dos municípios brasileiros e verificar se municípios com menor cobertura de saneamento apresentam maiores índices de internações por doenças relacionadas à falta de saneamento.

2. Preparação e Tratamento de Dados

A etapa de preparação dos dados envolveu a extração, limpeza e transformação de bases públicas para posterior armazenamento no PostgreSQL. Para melhorar a performance e facilitar as consultas SQL, o pré-processamento foi realizado em Python com a biblioteca pandas, permitindo remover colunas desnecessárias, tratar inconsistências e agregar informações relevantes ao projeto.

2.1. Indicadores de Saneamento (SNIS)

Os dados do SNIS (2021) passaram por seleção das variáveis principais: Código IBGE, município, e índices de atendimento de água e esgoto. Os nomes das colunas foram padronizados em snake_case para compatibilidade com o PostgreSQL. Também foi realizada a conversão dos indicadores percentuais de string para float, substituindo vírgulas por pontos. Valores ausentes relacionados ao esgoto foram preenchidos com 0, considerando a ausência de infraestrutura reportada.

2.2. Dados Epidemiológicos (SINAN)

Foram utilizados dados de cólera, leptospirose e esquistossomose referentes ao ano de 2021. Inicialmente, aplicou-se um filtro temporal para manter apenas registros do período analisado. Em seguida, os dados foram agregados por município utilizando o Código IBGE, somando os casos ao longo do ano.

2.3. Dados de Mortalidade (SIM)

Os microdados do SIM foram filtrados para manter apenas óbitos relacionados às doenças infecciosas intestinais (CID-10 A00–A09), reduzindo interferências de causas não associadas ao saneamento. Posteriormente, os registros individuais foram agrupados por município, gerando o total de óbitos por cidade e eliminando informações sensíveis desnecessárias.

2.4. Estruturação Final


Após o processo de ETL, os dados foram exportados em CSV padronizado e organizados . A estrutura final inclui:

1. saneamento_basico_mg_unificado: Contendo os índices de água e esgoto por município.
2. fato_mortalidade_geral: Registrando o total de óbitos por doenças intestinais (SIM).
3. fato_colera_2021: Registrando os eventos de infecção por cólera.
4. fato_leptospirose_2021: Registrando os eventos de infecção por leptospirose.
5. fato_esquistossomose_2021: Registrando os eventos de infecção por esquistossomose.

3. Engenharia reversa

3.1. Modelo Entidade-Relacionamento





3.2. Dicionário de dados

Entidade: Município

Atributo	Tipo	Domínio	Restrições	Descrição
cod_munip	INTEGER	Código IBGE	PK, NOT NULL, UNIQUE	Identificador do município
nome_munip	VARCHAR(100)	Texto	NOT NULL	Nome do município
pop_munip	INTEGER	≥ 0	NOT NULL	População total do município
pop_atendida_agua	INTEGER	≥ 0	NULL	População atendida por abastecimento de água
vol_agua_anual	DECIMAL(15,2)	≥ 0	NULL	Volume anual de água distribuída
vol_agua_eta	DECIMAL(15,2)	≥ 0	NULL	Volume de água tratada em ETA
vol_agua_desinfec	DECIMAL(15,2)	≥ 0	NULL	Volume de água submetida à desinfecção
vol_agua_fluor	DECIMAL(15,2)	≥ 0	NULL	Volume de água fluoretada
pop_atendida_esgoto	INTEGER	≥ 0	NULL	População atendida por coleta de esgoto
vol_esgoto_coletado	DECIMALNUMERIC(15,2)	≥ 0	NULL	Volume de esgoto coletado
vol_esgoto_tratado	DECIMAL(15,2)	≥ 0	NULL	Volume de esgoto tratado
amostra_cloro	INTEGER	≥ 0	NULL	Quantidade de amostras de cloro realizadas

amostra_cloro_irregular	INTEGER	≥ 0	NULL	Quantidade de amostras de cloro irregulares
amostra_turbidez	INTEGER	≥ 0	NULL	Quantidade de amostras de turbidez realizadas
amostra_turbidez_irregular	INTEGER	≥ 0	NULL	Quantidade de amostras de turbidez irregulares
amostra_coliformes	INTEGER	≥ 0	NULL	Quantidade de amostras de coliformes realizadas
amostra_coliformes_irregular	INTEGER	≥ 0	NULL	Quantidade de amostras de coliformes irregulares
cod_prestador	INTEGER	Código numérico	FK, NOT NULL	Prestador responsável pelo serviço

Entidade: Prestador

Atributo	Tipo	Domínio	Restrições	Descrição
cod_prestador	INTEGER	Código numérico	PK, NOT NULL, UNIQUE	Identificador do prestador de saneamento
nome_prestador	VARCHAR(150)	Texto	NOT NULL	Nome do prestador
sigla_prestador	VARCHAR(20)	Texto	NULL	Sigla do prestador
abrangencia_prestador	VARCHAR(50)	Municipal/Regional/Estadual/etc	NULL	Área de abrangência do prestador

tipo_prestador	VARCHAR(50)	Público/Privado/Misto/etc	NULL	Tipo do prestador
tipo_servico	VARCHAR(50)	Água/Esgoto/Ambos	NULL	Tipo de serviço prestado

Entidade: Doenca

Atributo	Tipo	Domínio	Restrições	Descrição
nome_doenca	VARCHAR(100)	Texto	PK, NOT NULL	Nome da doença

Relacionamento: Incidencia_de

Atributo	Tipo	Domínio	Restrições	Descrição
cod_munip	INTEGER	Código IBGE	FK, PK parcial	Município da incidência
nome_doenca	VARCHAR(100)	Texto	FK, PK parcial	Doença registrada
casos_totais	INTEGER	≥ 0	NOT NULL	Quantidade total de casos

Entidade: Doenca

Atributo	Tipo	Domínio	Restrições	Descrição
cod_munip	INTEGER	Código IBGE	FK, PK parcial	Município da incidência
total_casos_esquistossomose	INTEGER	≥ 0	NOT NULL	Quantidade total de casos de esquistossomose
total_casos_colera	INTEGER	≥ 0	NOT NULL	Quantidade total de casos de cólera

total_casos_leptospirose	INTEGER	≥ 0	NOT NULL	Quantidade total de casos de leptospirose
total_obitos	INTEGER	≥ 0	NOT NULL	Quantidade total de óbitos

Restrições Referenciais

Municipio → Prestador

- Municipio.cod_prestador
REFERENCES Prestador(cod_prestador)

Integridade:

- um município deve possuir um prestador válido.
-

Incidencia_de → Municipio

- Incidencia_de.cod_munip
REFERENCES Municipio(cod_munip)

Integridade:

- não pode existir incidência associada a município inexistente.
-

Incidencia_de → Doenca

- Incidencia_de.nome_doenca
REFERENCES Doenca(nome_doenca)

Integridade:

- não pode existir incidência de doença não cadastrada.